

MISSÃO AURORA SIGER

PROMPTS UTILIZADOS NO NCAS

Zero-shot, few-shot, structured outputs e simulação responsável

Documento técnico dos prompts e da simulação de IA generativa do Núcleo Cognitivo da Aurora Siger.

EQUIPE

Juan de Lucas Frois - RM563260
Flávia Roberta Pennachin - RM561860
Pedro Valente Toledo - RM570394
Renan Mano Otero - RM573615

FIAP - Ciência da Computação - Turma 1CCOA - 2026

1. Papel dos modelos de linguagem

Um Large Language Model processa texto em tokens e estima qual token deve vir a seguir. No pré-treinamento, o modelo observa grandes coleções de exemplos e ajusta parâmetros para reduzir erros de previsão. O prompt não altera esses parâmetros: ele fornece contexto e instruções para orientar uma execução.

Conceito	Aplicação no projeto
Token	Unidade de texto processada pelo modelo.
Pré-treinamento	Aprendizado anterior realizado pelo provedor do modelo.
Next Token Prediction	Mecanismo de previsão do próximo token provável.
Prompt Engineering	Projeto de instruções, contexto, restrições e formato.
Structured Output	Contrato que organiza a resposta em JSON válido.

Neste protótipo, nenhuma API é obrigatória. As respostas são simuladas localmente por regras determinísticas, o que permite demonstrar o fluxo de prompts sem custos, credenciais ou dependência de rede.

2. Estrutura adotada

Componente	Função
Papel	Define o assistente operacional da colônia.
Tarefa	Classifica o alerta e recomenda ação segura.
Contexto	Fornece o alerta e o módulo em JSON.
Regra	Exige F OR (E AND M) e bloqueio NOT(S AND D).
Restrições	Proíbe invenção de dados e preserva supervisão humana.
Formato	Define campos obrigatórios de um JSON válido.

3. Prompt zero-shot

Zero-shot significa que o modelo recebe a tarefa sem exemplos prévios. A instrução precisa ser explícita sobre papel, regra, limites e formato.

Você é o assistente operacional do Núcleo Cognitivo da Aurora Siger. Analise o alerta, aplique a regra F OR (E AND M), informe a prioridade e proponha uma ação segura. Não invente dados ausentes. Decisões críticas permanecem sob supervisão humana. Responda somente em JSON válido com: alerta_id, prioridade, resumo, acao_recomendada, requer_supervisao_humana e justificativa_logica.

ENTRADA:

```
{
  "alerta": {
    "id": "ALT-001",
    "data_hora": "2026-09-01T08:15:00",
    "modulo_id": "MOD-OXI-01",
    "tipo": "pressao_oxigenio",
    "falha": true,
    "critico": true,
    "consumo_elevado": false,
    "seguranca_ok": true,
    "dados_consistentes": true,
    "mensagem": "Queda de 18% na pressão da linha principal de oxigênio em cinco minutos.",
    "status": "aberto",
    "prioridade_calculada": "critica"
  },
  "modulo": {
    "id": "MOD-OXI-01",
    "nome": "Produção de Oxigênio",
    "essencial": true
  }
}
```

Por que esse prompt é adequado

Elemento	Efeito esperado
Regra explícita	Reduz ambiguidade na classificação.
Não inventar dados	Limita alucinações e inferências sem evidência.
Supervisão humana	Evita apresentar a saída como decisão autônoma final.
JSON obrigatório	Facilita validação, armazenamento e integração.

4. Prompt few-shot

Few-shot adiciona exemplos de entrada e saída antes do caso atual. Os exemplos mostram o padrão esperado sem criar uma regra baseada em características pessoais.

Exemplo 1 - falha crítica

```
{
  "entrada": {
    "alerta_id": "EX-001",
    "falha": true,
    "critico": true,
    "consumo_elevado": false,
    "modulo_essencial": true,
    "mensagem": "Falha confirmada no controle térmico."
  },
  "saida": {
    "alerta_id": "EX-001",
    "prioridade": "critica",
    "acao_recomendada": "Isolar o subsistema e acionar o Centro de Controle.",
    "requer_supervisao_humana": true
  }
}
```

Exemplo 2 - consumo alto em módulo não essencial

```
{
  "entrada": {
    "alerta_id": "EX-002",
    "falha": false,
    "critico": false,
    "consumo_elevado": true,
    "modulo_essencial": false,
    "mensagem": "Pico temporário durante experimento."
  },
  "saida": {
    "alerta_id": "EX-002",
    "prioridade": "normal",
    "acao_recomendada": "Registrar e manter monitoramento de rotina.",
    "requer_supervisao_humana": false
  }
}
```

Após os exemplos, o caso atual é inserido e o sistema solicita uma nova saída no mesmo formato. A seleção de exemplos inclui classes diferentes para reduzir o risco de sempre produzir prioridade alta.

5. Saída estruturada

O structured output define um contrato de dados. Mesmo em uma simulação, esse contrato torna a resposta previsível e permite sua persistência no histórico JSON.

Campo	Tipo	Finalidade
alerta_id	string	Rastreia a ocorrência de origem.
modulo	string	Identifica o sistema afetado.
prioridade	enum	critica, alta ou normal.
resumo	string	Sintetiza o fato sem inventar dados.
acao_recomendada	string	Propõe uma resposta operacional.
requer_supervisao_humana	boolean	Indica revisão obrigatória.
justificativa_logica	string	Explica as regras aplicadas.
observacao_etica	string	Registra limites e responsabilidade.

Exemplo de resposta simulada

```
{
  "alerta_id": "ALT-001",
  "modulo": "Produção de Oxigênio",
  "prioridade": "critica",
  "resumo": "Queda de 18% na pressão da linha principal de oxigênio.",
  "acao_recomendada": "Isolar o subsistema e acionar o Centro de Controle.",
  "requer_supervisao_humana": true,
  "justificativa_logica": "F OR (E AND M) = True; NOT(S AND D) = False.",
  "observacao_etica": "A resposta apoia, mas não substitui especialistas humanos."
}
```

6. Otimização da resposta

A qualidade foi avaliada de forma simulada em quatro dimensões. Cada dimensão tem alvo 1,00. O erro quadrático médio mede a distância entre a avaliação e esse alvo.

MSE = (1 / n) * SUM((valor_alvo - valor_obtido) ^ 2)

Critério	Prompt genérico	Prompt otimizado	Alvo
Clareza	0,55	0,92	1,00
Compleitude	0,60	0,95	1,00
Formato	0,40	1,00	1,00
Segurança	0,65	0,96	1,00
MSE	0,2112	0,0026	0,0000

Prompt inicial

Analise este alerta e diga o que fazer.

Prompt otimizado

Analise o alerta pela regra F OR (E AND M), não invente dados, classifique a prioridade, proponha ação segura, preserve supervisão humana e retorne somente JSON no esquema definido.

A redução simulada do MSE é de 98,8%. Em treinamento real, o gradiente descendente ajusta parâmetros do modelo. Aqui, a analogia está no ciclo de medir o erro, revisar a instrução e testar novamente. A regularização inspira a evitar regras excessivamente específicas; a generalização é observada em alertas de diferentes módulos.

Importante: as pontuações são didáticas e não representam experimento estatístico, treinamento de rede neural ou medição de um modelo comercial.

7. Memória, armazenamento e fluxo de dados

Etapa	Componente	O que acontece
1	Armazenamento	JSON e TXT persistem no dispositivo físico.
2	Barramentos	Bytes são transportados entre dispositivo, memória e CPU.
3	Memória RAM	Python mantém dicionários, listas, prompts e resultados.
4	Processador	Regras booleanas e serialização são executadas.
5	Escrita	Dados atualizados retornam ao armazenamento.

TXT foi escolhido para a trilha cronológica legível por pessoas. JSON foi escolhido para estruturas com tipos, listas e relações. Nenhum dado existe isolado: toda leitura e escrita depende da hierarquia de memória e do fluxo interno do computador.

8. Diversidade, ética e responsabilidade

Risco	Medida adotada no NCAS
Viés de priorização	Somente risco operacional participa da regra.
Discriminação	Características pessoais não são usadas na classificação.
Linguagem inadequada	Prompts exigem linguagem neutra e respeitosa.
Alucinação	O sistema proíbe inventar dados ausentes.
Automação excessiva	Prioridades crítica e alta exigem supervisão humana.
Falta de transparência	A saída inclui justificativa lógica e é registrada.

Diversidade na equipe de desenvolvimento e nos cenários de teste ajuda a identificar suposições invisíveis. Racismo estrutural e outras desigualdades podem aparecer em dados históricos, categorias ou linguagem. Por isso, ausência de um atributo sensível não basta: é necessário revisar variáveis indiretas, resultados e impactos.

O NCAS é um apoio à decisão. A responsabilidade final permanece com profissionais humanos capazes de considerar contexto, contestar resultados e corrigir o sistema.

9. Conclusão

Os prompts combinam instrução clara, contexto operacional, exemplos, formato estruturado e limites éticos. A simulação local demonstra o comportamento esperado sem exigir API. O resultado é reproduzível, auditável e coerente com o nível técnico da fase, ao mesmo tempo em que preserva supervisão humana e responsabilidade social.